

1. 다음 FashionMNIST 분류 성능을 개선하기 위한 방법입니다. 다음 지시사항에 따라 코드를 수정하고 물음에 답하세요. (과제물)

A. MLP 의 은닉층의 개수를 2 개로, 은닉층의 뉴런 개수를 2000 개로 증가시켜보세요.
개선된 모델은 총 모두 몇 개의 파라미터를 가지고 있나요?

5,612, 020 개

```
# 데이터셋 설정
num_train_samples = 55000
batch_size = 100
input_dim = 784
num_classes = 20

# 모델 설정
hidden_dim1 = 2000
hidden_dim2 = 2000

# 훈련 설정
epochs = 30
lr = 1e-2
momentum = 0.9
```

```
inputs = Input(shape=(input_dim,), name='input')
x = Dense(hidden_dim1, activation='relu', name='hidden1')(inputs)
x = Dense(hidden_dim2, activation='relu', name='hidden2')(x)
x = Dense(num_classes, activation='softmax', name='output')(x)
model = Model(inputs, x, name='mlp')
```

```
# 모델 확인
model.summary()
```

... Model: "mlp"

Layer (type)	Output Shape	Param #
input (InputLayer)	(None, 784)	0
hidden1 (Dense)	(None, 2000)	1,570,000
hidden2 (Dense)	(None, 2000)	4,002,000
output (Dense)	(None, 20)	40,020

Total params: 5,612,020 (21.41 MB)
Trainable params: 5,612,020 (21.41 MB)
Non-trainable params: 0 (0.00 B)

B. A 의 모델을 학습하고, 훈련세트, 검증세트, 테스트세트의 정확도를 보고하세요. (결과 스크린샷 첨부 및 최종 정확도 작성)

훈련 세트 96.08%

검증세트 90.18%

테스트 세트 89.93%

```
# Epoch 30의 훈련 및 검증 정확도 출력
print(f"훈련 세트 정확도: {history.history['categorical_accuracy'][-1]:.4f}")
print(f"검증 세트 정확도: {history.history['val_categorical_accuracy'][-1]:.4f}")

...   훈련 세트 정확도: 0.9608
      검증 세트 정확도: 0.9018

# 학습된 모델의 성능을 테스트 세트에서 평가합니다.
model.compile(optimizer=optimizer,
              loss=loss,
              metrics=[metric])
model.evaluate(test_dataset)

...   100/100 ————— 1s 4ms/step - categorical_accuracy: 0.8993 - loss: 0.2968
      [0.29440638422966003, 0.8993200063705444]
```

C. B 에서 테스트 성능이 개선되었다면, 그 이유를 서술하세요.

뉴런 수가 2000 로 늘어남에 따라 모델이 학습 데이터의 복잡하고 미세한 패턴을 더 잘 학습할 수 있게 되었다.

은닉층을 2 개로 늘림으로써 활성화 함수(ReLU)를 거치는 횟수가 늘어나 데이터의 비선형성을 더 효과적으로 분리하고 학습할 수 있게 되었다.

D. B 에서 모델의 학습 epoch 를 60 으로 늘려서 학습하고, 훈련세트, 검증세트, 테스트세트 정확도를 보고하세요.

훈련 세트 99.42%

검증 세트 90.20%

테스트 세트 90.27%

```
# Epoch 30의 훈련 및 검증 정확도 출력
print(f"훈련 세트 정확도: {history.history['categorical_accuracy'][-1]:.4f}")
print(f"검증 세트 정확도: {history.history['val_categorical_accuracy'][-1]:.4f}")

... 훈련 세트 정확도: 0.9942
검증 세트 정확도: 0.9020
```

```
# 학습된 모델의 성능을 테스트 세트에서 평가합니다.
model.compile(optimizer=optimizer,
              loss=loss,
              metrics=[metric])
model.evaluate(test_dataset)

... 100/100 ————— 1s 4ms/step - categorical_accuracy: 0.9025 - loss: 0.3476
[0.3417568802833557, 0.902733325958252]
```

E. D 에서 테스트 성능이 개선되었다면, 그 이유를 서술하세요.

30 Epoch 에서는 과소적합 상태였을 수 있는데, 학습 횟수를 늘림으로써 모델이 학습 데이터를 익히기 위한 충분한 시간을 주었다. 이로 인해 경사 하강법을 통해 손실 함수의 최솟값에 더 가깝게 수렴했을 것이다.

F. FashionMNIST 분류 성능을 더욱 향상시킬 아이디어가 있다면 서술하세요.

현재 훈련 세트에 비해 테스트 세트의 정확률이 낮다. 이것으로 모델이 과적합 상태임을 알 수 있는데, 이를 해결하기 위해서는 일반화 능력을 키워야 한다.

1, Drop out 기법을 활용.

학습 시에 임의로 일부 뉴런을 비활성화 시키고, 평가 및 테스트 시에는 모든 뉴런을 활성화시키는 방법으로 특정 픽셀에 과도하게 집착하는 문제를 개선할 수 있다.

추가적으로 매번 다른 구조의 신경망을 학습시키는 효과도 얻을 수 있다.

2, 가중치 규제.

가중치가 커서 작은 변화에도 민감하게 반응하여 모델이 훈련 데이터의 노이즈까지 학습하는 문제를 개선해야 한다. 이를 위해 손실을 계산할 때 정답을 못 맞힌 정도에 가중치들의 크기를 더하면 모델이 가중치를 0 에 가깝게 유지하여 모델의 결정 경계가 부드러워지는 효과를 볼 수 있다.

3, CNN 도입.

2 차원 이미지를 1 차원으로 평탄화 하는 과정에서 손실되는 데이터를 지키기 위해 CNN 모델을 이용할 수 있다. 또한 CNN 의 모델을 도입하면 하나의 필터가 이미지 전체 영역을 이동하기 때문에 지역적인 특징 추출한다는 특성과 사물의 위치가 바뀌어도 동일한 특징으로 인식하는 위치 불변성의 특성을 얻어 일반화 능력을 향상시킬 수 있다.

4, Data Augmentation

훈련 데이터의 이미지를 이동, 회전, 반전시키는 등의 인위적 변형으로 데이터의 다양성을 늘리면 모델이 더 다양한 형태의 이미지 패턴을 학습하여 일반화 능력이 향상될 수 있다.